



Microproyecto 3

Café Aurora

Jhon Ramos
Santiago Arce



Problema

Café Aurora es una cafetería local, especializada en café artesanal y productos de panadería. La empresa ha crecido rápidamente en los últimos meses y busca tomar decisiones estratégicas basadas en datos reales para aumentar sus ingresos diarios.

Necesidades:

- Predecir el ingreso diario en función de variables como número de clientes, gasto promedio, y presupuesto en marketing.
- Tener una herramienta sencilla y accesible que les permita estimar sus ingresos con diferentes escenarios.



Requerimientos:

- Modelo de machine learning entrenado con datos históricos de operación.
- Implementación de una API para consumo en tiempo real.
- Interfaz simple para ingresar variables operativas (clientes, marketing, ticket promedio).

Restricciones:

- No se cuenta con un historial financiero detallado, solo con métricas operativas.
- El modelo debe ejecutarse usando servicios de **Azure Machine Learning**, como parte de un piloto académico.



Dataset

Coffee Shop Daily Revenue

El dataset contiene **2.000 registros simulados** que reflejan el **rendimiento diario** de una cafetería durante un periodo extendido.

Cada fila representa un **día de operación**, e incluye variables clave que afectan directamente los ingresos diarios.

Objetivo del proyecto:

Predecir los ingresos diarios de la cafetería a partir de variables operativas y de entorno.

Variables principales:

- **Number_of_Customers_Per_Day** 🧑: cantidad de clientes diarios
- **Average_Order_Value** 💵: ticket promedio (\$)
- **Marketing_Spend_Per_Day** 📣: inversión diaria en marketing (\$)
- **Operating_Hours_Per_Day** ⌚: horas operativas
- **Location_Foot_Traffic** 🚶: tránsito peatonal en la zona
- **Number_of_Employees** 👥: empleados en turno
- **Daily_Revenue** 📈: **variable objetivo** – ingresos diarios en dólares




Fuente: Kaggle



[Coffee Shop Daily Revenue Dataset](#)

Análisis de datos



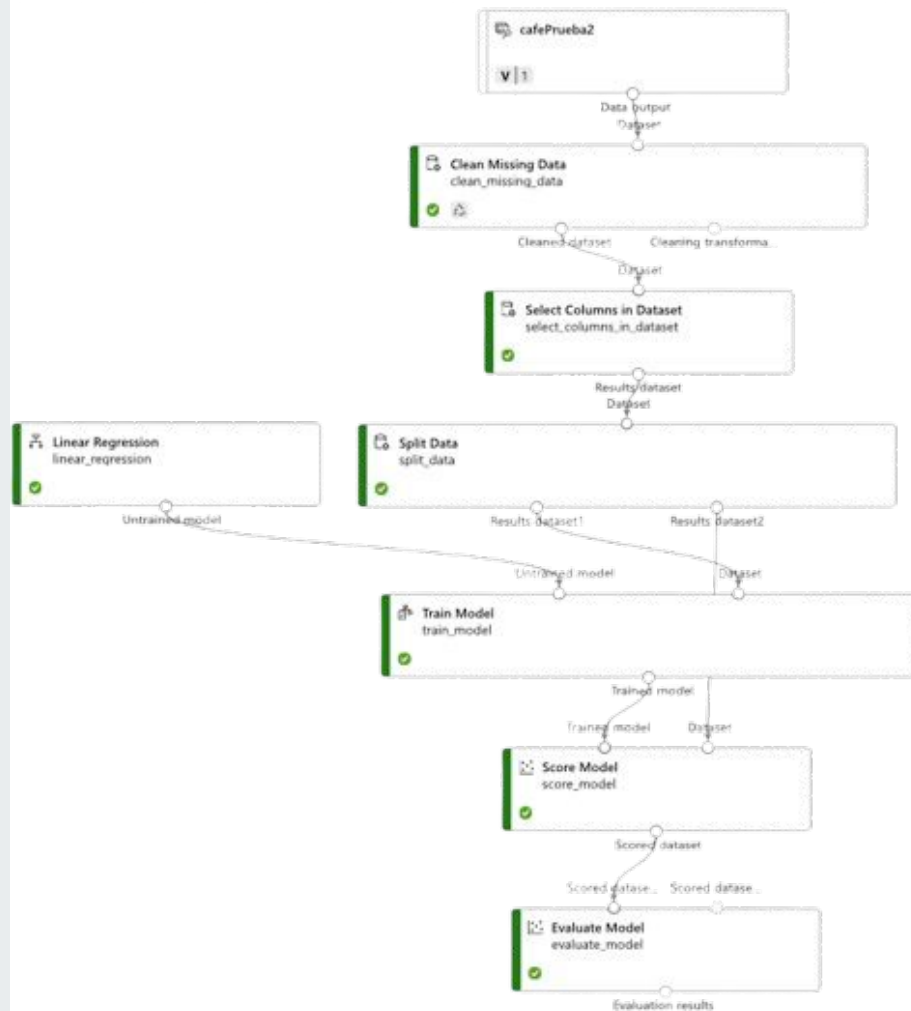
| | Daily_Revenue |
|-----------------------------|---------------|
| Number_of_Customers_Per_Day | 0.736461 |
| Average_Order_Value | 0.535694 |
| Operating_Hours_Per_Day | -0.005323 |
| Number_of_Employees | 0.003295 |
| Marketing_Spend_Per_Day | 0.254812 |
| Location_Foot_Traffic | 0.013469 |
| Daily_Revenue | 1.000000 |

Entrenamiento del modelo

Linear Regression

Training Data: 70%
Testing data: 30%

| | | |
|---|---|---|
| <div><div></div><div></div></div> <div>Coefficient_of_Determi...</div> <div>0.8857602</div> | <div><div></div><div></div></div> <div>Mean_Absolute_Error</div> <div>253.1211</div> | <div><div></div><div></div></div> <div>Relative_Absolute_Error</div> <div>0.3208620</div> |
| <div><div></div><div></div></div> <div>Relative_Squared_Error</div> <div>0.1142398</div> | <div><div></div><div></div></div> <div>Root_Mean_Squared_E...</div> <div>326.2835</div> | |



Entrenamiento del modelo

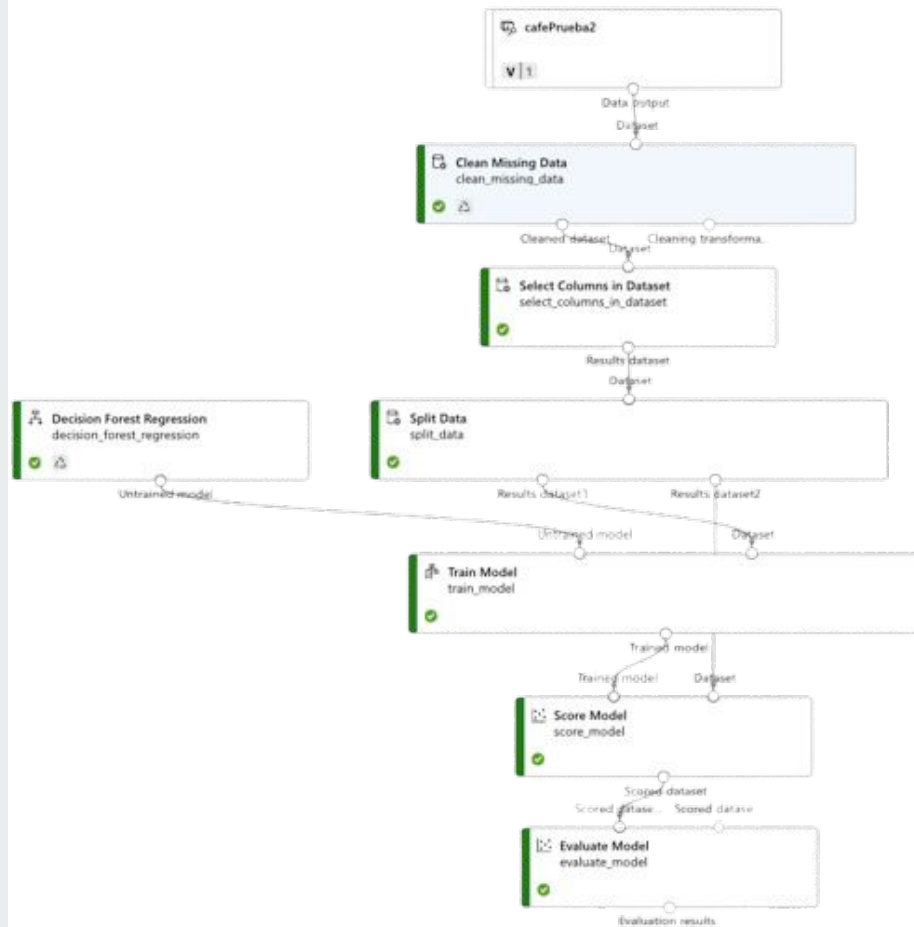
Decision Forest Regression

numero de arboles: 8

Training data: 70%

Testing data: 30%

| | | |
|---|---|---|
| <div><div></div><div></div></div> <div>Coefficient_of_Determi...</div> <div>0.9438429</div> | <div><div></div><div></div></div> <div>Mean_Absolute_Error</div> <div>189.6138</div> | <div><div></div><div></div></div> <div>Relative_Absolute_Error</div> <div>0.2319312</div> |
| <div><div></div><div></div></div> <div>Relative_Squared_Error</div> <div>0.05615714</div> | <div><div></div><div></div></div> <div>Root_Mean_Squared_E...</div> <div>236.8758</div> | |



Soluciones

| | | |
|---|---|--|
| Flask en instancia APP Service | Serverless con Azure Functions + Modelo en Azure blob o MI Studio | Flask + Modelo ML en Maquina virtual |
| Desplegar la API Flask directamente como un servicio web en Azure App Service. | Convertir la predicción en una función sin servidor que se ejecuta solo cuando se llama. | Deploy de la API y modelo en una VM Linux/Windows tradicional. |
| Más simple de configurar y mantener. Escalado automático incluido. Integración sencilla con GitHub y CI/CD. Costos menores en escenarios simples. | Pago por uso (solo pagas cuando se usa). Alta escalabilidad automática. Fácil de conectar con otros servicios Azure. | Total control del sistema operativo y entorno. Útil para pruebas locales o entornos de desarrollo. Sin necesidad de orquestación compleja. |
| Menor control sobre el entorno (no puedes personalizar tanto como en un contenedor). Escalabilidad limitada comparado con AKS. Menos apropiado si en el futuro necesitas múltiples microservicios o un clúster. | Tiempo de "cold start" (puede tardar en responder si no está activo). Límite de tiempo de ejecución (ideal para predicciones rápidas). Más complejo el manejo del archivo .pkl (debe estar en almacenamiento externo). | No escala automáticamente. Mayor riesgo de fallos si no se configura HA (alta disponibilidad). Más difícil de mantener y actualizar que AKS o App Service. |



Flask en instancia APP Service

El modelo de ML se expone mediante una API Flask en un contenedor Docker, desplegado en AKS, y consumido desde Unity.

Escalabilidad automática (Kubernetes autoscaling).

Gestión robusta de contenedores.

Integración nativa con otros servicios de Azure.

Ideal para producción y múltiples usuarios concurrentes.

Mayor complejidad de despliegue.

Requiere conocimientos de Kubernetes.

Puede generar costos mayores si no se configura correctamente.

Café Aurora

docker image



API



Modelo ML.pkl



HTTPS



Json Response



Uizard

←

→

↺

🌐 app.uizard.io/prototypes/og64LY61zjtPyZQ7gabV

U

Free

RevenuePredictor

477/400 components used 120%

📄

🔍

↶

↷

—

+

Screen

📄

Template

📐

Shape

📄

Text

🖼️

Image

🔗

Icon

📄

Button

📄

Form

📄

Brand

🌟

proposals

RevenuePredictor

Estimated Number of Customers

138

Planned Marketing Investment (\$)

138

Average Order Value (\$)

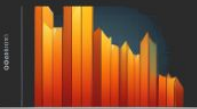
138

Submit

RevenuePredictor

Predicted Revenue

\$5,230.00




The predicted daily revenue is calculated using historical sales data, seasonal trends, and current market conditions. This estimation helps in planning and resource allocation for optimal business operations.

About RevenuePredictor

App Purpose

RevenuePredictor is designed to help businesses forecast future revenue trends with precision. Utilizing advanced algorithms, it provides insights that empower decision-makers to strategize effectively.

Developer Bio



Alex Johnson

Software Engineer and Data Enthusiast

With a passion for data-driven solutions, Alex embarked on creating RevenuePredictor to simplify the revenue forecasting process for businesses of all sizes. With over a decade of experience in the tech industry, Alex is committed to delivering innovative solutions that drive business success.

Contact Support



Costos


-AKS Standard Ds2 v2 :~85,41 US\$ Mensual

-Entrenamiento modelo :1h ~ \$1





Demo





Capuccino 2,99 3,85*
Café Latte 3,99 4,49*
Latte Macchiato 3,85 4,49
Kaffeevollkornbrot 3,85 4,49
Weißbrot 3,85 4,49
Cranberry M...
*nur gegen Aufpreis

Tost Weißer Dark Chocolate 4,99
Tost Caramel Macchiato 2,99
Tost Chili Latte 3,99
Tost Weißer Dark Chocolate 3,99

Bio Rahm in Speck ev. 2,70
Frühstücksgewinn 0-Saft (0,2l)